Desafío Taller II - Modelo de Análisis de Sentimiento

Objetivo

Construir un pipeline completo de análisis de sentimiento, desde la obtención y preprocesamiento del dataset, pasando por distintas formas de representar texto numéricamente, hasta el entrenamiento, evaluación y despliegue de un modelo en un entorno controlado.

Objetivos específicos

1. Obtener y preprocesar un dataset para análisis de sentimiento.
2. Representar el texto numéricamente con TF-IDF (unigramas y bigramas), BoW y embeddings.
3. Entrenar y validar modelos de Machine Learning con el dataset procesado.
4. Construir, en conjunto con el resto del curso, un banco de oraciones adversariales que expongan los límites de estas representaciones.
5. Evaluar y comparar cuatro enfoques de representación/clasificación sobre ese banco: TF-IDF unigrama, TF-IDF bigrama, embeddings (vectores pre-entrenados) y un pipeline pre-entrenado de Hugging Face.
6. Crear una aplicación web básica para realizar inferencias sobre el modelo seleccionado

Modalidad de trabajo

El trabajo se puede desarrollar de manera grupal (hasta 5 integrantes). Cada grupo va a trabajar en un repositorio Git (GitHub o similar)

Entregas

- Dataset extraído y preprocesado
- Dataset vectorizado. Vectorización BoW, TF-IDF unigrama, TF-IDF bigrama, embeddings, pipeline HF pre-entrenado) con el tamaño de vocabulario resultante en cada caso.
- Comparativa de modelos entrenados (evaluación). Resultados de los cuatro enfoques evaluados sobre el test set adversarial del curso (BoW, TF-IDF unigrama, TF-IDF bigrama, embeddings, pipeline HF pre-entrenado). Calcular métricas (accuracy, precision, recall, F1, matriz de confusión) para cada uno, y una conclusión explícita indicando qué modelo van a utilizar y por qué.

- Entrega final (ver más abajo)

Banco de oraciones adversariales

Durante la clase de “Word Embeddings.Word2Vec, similitud coseno, analogías semánticas. Uso de embeddings pre-entrenados”, cada grupo va a sumar 2-3 oraciones a un banco común (Google Sheet compartido), usando plantillas con hueco para negación, inversión sintáctica y afijos negativos. Ese banco, curado en conjunto al inicio de la clase de evaluación, es el que se usa en la última entrega parcial para comparar los cuatro enfoques.

Entrega final

- Informe integrador
- Link al repositorio Git actualizado
- Defensa con cliente (Strata)

Como sugerencia, se propone la siguiente estructura mínima de secciones para el informe:

1. Introducción: descripción del problema y objetivo del análisis.
2. Dataset: fuente (Trustpilot), cantidad de reseñas, variables, etiquetas.
3. Preprocesamiento: pasos realizados (limpieza, tokenización, lematización, etc.).
4. Representación del texto: TF-IDF, embeddings, etc.
5. Modelos probados: descripción breve de cada uno (NB, LogReg, RF, MLP, etc.).
6. Optimización: hiperparámetros ajustados y metodología (Grid/Random Search).
7. Resultados: tabla comparativa con métricas (Accuracy, F1 macro).
8. Análisis e interpretación: discusión de errores, palabras relevantes, desempeño por clase.
9. Conclusiones: modelo final elegido, limitaciones y posibles mejoras

Asimismo, en la defensa con el cliente se deben incluir los siguientes temas:

- Gráfico conceptual de los pasos llevados a cabo para obtener un modelo de sentiment analysis a partir de opiniones.
- Breve descripción del dataset y objetivo.
- Visualizaciones clave (provenientes del EDA, del rendimiento de modelos, etc).
- Explicación del modelo elegido y sus métricas de rendimiento.
- Reflexión final: qué aprendieron del proceso, qué mejorarían en futuros proyectos.